

俞哲

研究助理| 可信语言模型与智能体AI

香港科技大学（广州）| LAI Lab · 浙江大学| IFRC Lab

zyu@zju-if.com · 个人主页 · Google Scholar · GitHub

研究简介

研究聚焦可信语言模型与智能体AI：分析模型如何在内部表征知识、证据来源、冲突与风险，研究这些信号为何未能稳定引导生成与工具调用，并通过白盒监测、审计规划和可验证保障机制提升模型行动与部署的可靠性。

当前科研任职

香港科技大学（广州）

LAI Lab 研究助理；导师：秦成伟教授

2026年5月– 至今

广州，中国

浙江大学滨江研究院

IFRC Lab 研究实习生；导师：韩蒙、邢文鹏

2025年11月– 至今

杭州，中国

- 围绕可信语言模型、RAG 忠实性、智能体安全、审计可靠性与可验证部署开展研究，参与广东省重点研发计划与国家重点研发计划青年科学家项目。

教育与访学经历

浙江传媒学院

人工智能专业，工学学士在读；本科导师：曾昊

2023年– 预计2027年

杭州，中国

马来亚大学

访问学生

2025年1月– 2025年2月

吉隆坡，马来西亚

西湖大学

访问学生；导师：张紫阳

2024年3月– 2024年9月

杭州，中国

代表性研究贡献

- 检索增强生成与幻觉检测**：主导DISF 的问题定义、方法设计、实验与论文撰写，提出刻画Conflict、Drift 与Instability 的双路径白盒框架；论文被ACL 2026 录用。
- 证据归因与干预**：围绕检索-记忆冲突构建内部信号方法，包括面向token 级training-free 干预的FIDES，以及区分相同输出背后参数记忆与检索证据路径的Attribution Blind Spot。
- 审计与评估可靠性**：PLAIT 将幻觉分数转化为保留父级结构的审计计划；GAVEL 通过配对审计与pair-level correction 揭示item calibration 无法保证实验对比有效。
- 表征-行动分离**：主导Knowing Is Not Acting 与Whose Thoughts?，揭示来源与冲突信息虽可被线性解码，却可能在工具选择或答案策略中失效；两篇论文均投稿至NeurIPS 2026。
- 监测与可验证部署**：主导LatentAudit 与RETINA-SAFE / ECRT 的白盒监测和高风险医疗分诊研究，并参与隐私保护模型归属验证工作ZK-FPE；后者被ACM TURC 2026 录用。

已录用与发表论文

- Zhe Yu***, Wenpeng Xing*, Wenjie Luo, Weize Xu, Lingtong Huang, Yourong Chen, Changting Lin, Meng Han. *DISF: Detecting Hallucinations in Retrieval-Augmented Generation via Dual-path Internal State Forcing Framework*. **ACL 2026**. [PDF]
- Zhiguo Ma*, **Zhe Yu**, Wenpeng Xing, Yourong Chen, Meng Han. *ZK-FPE: Blockchain-Verifiable Model Fingerprinting with Zero-Knowledge Privacy for Ownership Attribution*. **ACM TURC 2026**. [PDF]
- Weiping Yu, Weihang Wang, Mingyuan Yan, Keyang He, **Zhe Yu**, Wenpeng Xing, Liyuan Liu, Meng Han. *Trusted Metadata-Coordinated Tiered Off-Chain Storage for Recovery-Safe and Low-Latency IoT Data Management*. *Electronics* (MDPI).
- F. Zhou, C. Chang, Q. Chang, H. Zhang, **Zhe Yu**, W. Liu, J. Li, J. Yang. *Orthogonal salinity and temperature detection via paralleled dual all-fiber interferometers*. *Optics Communications*, 583 (2025): 131688. [DOI]
- Zhe Yu**, H. Zeng, Y. Zhao, X. Zhang, Z. Wang, Y. Tao, M. Yuan, X. Sun. *Bibliometric analysis of physical education research in China from 2014 to 2024*. *ACM ICETM*, 2025, pp. 128–132. [DOI]

代表性在投稿件

1. **Zhe Yu**, Yunzhao Wei, Wenpeng Xing, Wenjie Luo, Zaobo He, Quan Chen, Meng Han. *PLAIT: From Hallucination Scores to Parent-Preserving Audit Plans*. **AAAI 2027 在投**. [PDF]

2. **Zhe Yu***, Wenpeng Xing*, Bo Yang, Chen Ye, Gaolei Li, Yunzhao Wei, Meng Han. *The Attribution Blind Spot: Detecting When Language Models Rely on Memory Rather Than Retrieved Context*. **AAAI 2027 在投**. [PDF]

3. **Zhe Yu***, Wenpeng Xing*, Chen Ye, Xuyang Teng, Bo Yang, Changting Lin, Meng Han. *Calibration Does Not Certify a Contrast: Identification and Correction for LLM Evaluators*. **AAAI 2027 在投**. [PDF]

4. **Zhe Yu**, Wenpeng Xing, Zhenhua Xu, Xingxing Yang, Meng Han. *Knowing Is Not Acting: Representation–Action Dissociation in Indirect Prompt Injection*. **NeurIPS 2026 在投**. [PDF]

5. **Zhe Yu**, Wenpeng Xing, Zhenhua Xu, Ruiqi Zhang, Meng Han. *Whose Thoughts? Chain-of-Thought Override in Reasoning-Tuned Language Models*. **NeurIPS 2026 在投**. [PDF]

6. **Zhe Yu***, Wenpeng Xing*, Tiancheng Zhao, Mohan Li, Changting Lin, Meng Han. *FIDES: Faithful Inference via Deep Evidence Signals for Retrieval-Memory Conflict in RAG*. ARR / EMNLP 在投. [PDF]

7. **Zhe Yu***, Wenpeng Xing*, Gaolei Li, Shuguang Xiong, Hongzhi Wang, Xuyang Teng, Meng Han. *Cordon-MAS: Defending RAG against Knowledge Poisoning via Information-Flow Control*. ARR / EMNLP 在投. [arXiv]

8. **Zhe Yu***, Wenpeng Xing*, Yunzhao Wei, Hongzhi Wang, Xuyang Teng, Meng Han. *Composition Collapse: Stable Factual Knowledge Does Not Imply Compositional Reasoning*. ARR / EMNLP 在投. [arXiv]

9. Zhenhua Xu, Qichen Liu, Zhebo Wang, **Zhe Yu**, Xixiang Zhao, Wenpeng Xing, Dezhang Kong, Mohan Li, Meng Han. *Fingerprint Vector: Enabling Scalable and Efficient Model Fingerprint Transfer via Vector Addition*. ARR / EMNLP 在投.

10. **Zhe Yu***, Wenpeng Xing*, Meng Han. *LatentAudit: Real-Time White-Box Faithfulness Monitoring for Retrieval-Augmented Generation with Verifiable Deployment*. CoLM 2026 在投. [arXiv]

11. **Zhe Yu***, Wenpeng Xing*, Meng Han. *From Retinal Evidence to Safe Decisions: RETINA-SAFE and ECRT for Hallucination Risk Triage in Medical LLMs*. MICCAI 2026 在投. [arXiv]

* 表示共同一作；投稿状态为2026 年8 月时间快照。

专利

1. **俞哲**, 邢文鹏, 韩蒙。《一种基于双路径内部状态强迫逻辑的检索增强生成大语言模型幻觉检测方法》。中国发明专利申请号202610260408X，实质审查中。

2. 韩蒙, **俞哲**, 胡佳妍, 李荣昌, 邢文鹏, 于静怡, 洪榛, 等。《一种基于自适应顺序统计量聚合的大语言模型幻觉检测后处理方法、系统、设备及介质》。中国发明专利申请号2026107898102, 申请日：2026年6月3日，已受理。

3. **俞哲**, 胡佳妍, 于静怡, 于苇杭, 邢文鹏, 熊婧, 陈友荣, 洪榛, 等。《一种基于多维异构特征融合的大语言模型幻觉检测方法、系统及设备》。中国发明专利申请号2026107899270, 申请日：2026年6月3日，已受理。

企业研发经历

BoostEngine
研发实习生（全栈开发/ AI Agents）

2025年7月– 2025年10月
杭州，中国

- 使用React、TypeScript、Vite 与Chrome APIs 构建面向TikTok Shop 的多品牌Manifest V3 Chrome Extension，覆盖20 个区域站点与9 种语言环境。
- 开发支持8000+ 达人合作的数据分析服务，并构建包含防环、队列合并、监控与告警的FastAPI / Redis / MySQL 双向同步系统。

荣誉奖项与技术能力

- “建行杯”浙江省国际大学生创新大赛银奖，2024，项目《脊柱侧弯检测AI 系统》。
- 研究栈：Python, PyTorch, Hugging Face Transformers, scikit-learn, NumPy, pandas, FAISS, vLLM, W&B, MATLAB.
- 工程栈：TypeScript / JavaScript, Java, React, FastAPI, Spring Boot, SQLAlchemy, MyBatis-Plus, MySQL, Redis, Docker, Chrome Extensions.