俞哲

浙江传媒学院· 人工智能（工学学士在读）

Research Interest: Trustworthy LLMs / RAG Faithfulness

2th.l0ren17@gmail.com zyu@zju-if.com 235703223@stu.cuz.edu.cn

Phone/WeChat: +86 18257166408 (Yy7z_1) Homepage Google Scholar

当前任职

浙江大学滨江研究院 2025年11月– 至今

研究实习生；导师：邢文鹏、韩蒙 杭州，中国

- 参与项目：多模态大模型安全系统研究与应用（广东省重点研发计划），2025年11月– 至今。
- 参与项目：基于区块链的新型信任体系（国家重点研发计划- 青年科学家项目），2025年11月– 至今。

教育背景

浙江大学滨江研究院 2025年11月– 至今

研究实习生 杭州，中国

马来亚大学 2025年1月– 2025年2月

访问学生 吉隆坡，马来西亚

西湖大学 2024年3月– 2024年7月

访问学生（导师：张紫阳） 杭州，中国

浙江传媒学院 2023年– 至今（预计2027 年毕业）

人工智能专业，工学学士在读（导师：曾昊） 杭州，中国

研究概述

- 研究聚焦于Trustworthy LLMs，主线为检索增强生成（RAG）的忠实性建模、幻觉检测、风险感知解码与可验证部署，已形成ACL Findings 2026 已录用论文DISF，以及FORGE、LatentAudit 等系列工作。
- 围绕医疗大模型安全，持续研究证据冲突、证据缺失与风险分诊问题，参与构建RETINA-SAFE / ECRT 的benchmark、task design 与方法框架，关注高风险场景下的evidence-aware safety。
- 同时关注可验证归属与可信部署，探索零知识证明、区块链与模型指纹所有权验证相结合的技术路线，并形成ZK-FPE 等在投稿件。

科研经历

浙江大学滨江研究院 2025年11月– 至今

研究实习生（导师：邢文鹏、韩蒙） 杭州，中国

- 参与广东省重点研发计划“多模态大模型安全系统研究与应用”，围绕Trustworthy LLMs、RAG 忠实性、白盒监测与医疗大模型安全开展研究，相关产出包括DISF、FORGE、LatentAudit 与RETINA-SAFE / ECRT。
- 主导DISF 的问题定义、方法设计、实验组织与论文撰写，面向parametric memory 与retrieved evidence 冲突导致的RAG 忠实性幻觉，提出dual-path internal-state forcing 白盒框架，显式刻画Conflict、Drift 与Instability 三类内部信号；论文已被ACL Findings 2026 录用。

- 主导FORGE 的任务定义、解码框架设计、实验评估与论文撰写，面向retrieval-memory conflict 构建training-free risk-guided decoding，将Opposition（CTX/NOCTX 分布JS 散度）、Shift（cross-layer hidden-state divergence）与Noise（mid/final-layer KL）融合为token-level contrast weight；在NQ-Swap、PopQA、TriviaQA 与LLaMA2-7B、Mistral-7B、LLaMA3-8B、Qwen3-8B 上验证，Context Fidelity 相比Standard RAG 提升14.2–28.3点。
- 主导LatentAudit 的监测任务设定、方法设计、跨模型实验与论文撰写，提出基于residual-stream geometry 与Mahalanobis distance 的real-time white-box monitor，在PubMedQA 上达到0.942 AUROC、额外开销0.77 ms，并验证fixed-point audit rule 可支撑Groth16 public verification。
- 主导RETINA-SAFE / ECRT 的benchmark 构建、task design、实验评估与论文撰写，围绕diabetic retinopathy 高风险决策建立12,522 样本的evidence-grounded benchmark，定义E-Align、E-Conflict、E-Gap 三类任务，并提出two-stage Evidence-Conditioned Risk Triage；Stage-1 balanced accuracy 相比外部uncertainty / self-consistency 基线提升0.15–0.19。
- 参与国家重点研发计划- 青年科学家项目“基于区块链的新型信任体系”，围绕区块链、零知识证明与链上/链下协同信任开展研究，相关工作包括ZK-FPE、ZK-VOT 与*Trusted Metadata-Coordinated Tiered Off-Chain Storage*。
- 在ZK-FPE 中主要负责实验改进与完善、图表绘制、结果执行与辅助撰写，围绕零知识证明与区块链模型指纹归属验证完成proof generation、verification cost 与链上开销实验，支撑隐私保护条件下的所有权验证结论。
- 参与ZK-VOT 与*Trusted Metadata-Coordinated Tiered Off-Chain Storage for Recovery-Safe and Low-Latency IoT Data Management* 的相关实验与投稿工作，聚焦链上/链下互信、零知识可验证传输、分层链下存储与恢复安全场景下的低时延数据管理。

马来亚大学 2025年1月– 2025年2月

访问学生 吉隆坡，马来西亚

- 在英文授课与国际化交流环境中系统学习人工智能相关内容，训练主题覆盖自然语言处理、机器人技术、机器学习与计算机视觉，并完成跨文化学术展示与讨论。
- 基于Python 完成机器人行走、转向与拍照控制实践；同时参与与新加坡国立大学（National University of Singapore）及新加坡国立大学医院（National University Hospital, NUH）合作的医疗数据分析建模练习。

西湖大学 2024年3月– 2024年7月

光学实验室访问学生（导师：张紫阳） 杭州，中国

- 围绕集成光学中光束偏转器角度仿真的定量分析问题，基于MATLAB 设计图像特征提取流程，通过ROI 裁剪、中轴线干扰抑制、灰度平滑、Otsu 阈值分割、Canny 边缘检测与霍夫直线拟合，对仿真光场中的主传播轨迹进行自动识别并反演偏转角。
- 对多组仿真图像进行批量测角、均值统计与趋势可视化，得到偏转角约5.46 至7.92 度的变化区间，用于分析扫描规律、辅助参数标定与实验流程更新。

已录用论文

1. **Zhe Yu***, Wenpeng Xing*, Wenjie Luo, Weize Xu, Lingtong Huang, Yourong Chen, Changting Lin, Meng Han†. *DISF: Detecting Hallucinations in Retrieval-Augmented Generation via Dual-path Internal State Forcing Framework*. ACL Findings 2026 已录用；OpenReview.

2. F. Zhou, C. Chang, Q. Chang, H. Zhang, **Zhe Yu**, W. Liu, J. Li, J. Yang. *Orthogonal salinity and temperature detection via paralleled dual all-fiber interferometers. Optics Communications*, 583 (2025): 131688. [DOI]

3. **Zhe Yu**, H. Zeng, Y. Zhao, X. Zhang, Z. Wang, Y. Tao, M. Yuan, X. Sun. *Bibliometric analysis of physical education research in China from 2014 to 2024.* In *Proceedings of the 2024 7th International Conference on Educational Technology Management.* ACM, 2025, pp. 128–132. [DOI]

代表性在投稿件

1. **Zhe Yu***, Wenpeng Xing*, Meng Han†. *LatentAudit: Real-Time White-Box Faithfulness Monitoring for Retrieval-Augmented Generation with Verifiable Deployment.* CoLM 2026 在投；arXiv:2604.05358.
2. **Zhe Yu***, Wenpeng Xing*, Tiancheng Zhao, Mohan Li, Changting Lin, Meng Han†. *FORGE: Faithful Output via Risk-Guided Decoding for Retrieval-Memory Conflict in RAG.* ARR / EMNLP 在投；OpenReview.
3. **Zhe Yu***, Wenpeng Xing*, Meng Han†. *From Retinal Evidence to Safe Decisions: RETINA-SAFE and ECRT for Hallucination Risk Triage in Medical LLMs.* MICCAI 2026 在投；arXiv:2604.05348.
4. Zhiguo Ma*, Wenpeng Xing*, **Zhe Yu***, Yourong Chen, Meng Han†. *ZK-FPE: Blockchain-Verifiable Model Fingerprinting with Zero-Knowledge Privacy for Ownership Attribution. Blockchain: Research and Applications* 在投.
5. Weiping Yu, Weihan Wang, Mingyuan Yan, Keyang He, **Zhe Yu**, Wenpeng Xing, Liyuan Liu, Meng Han†. *Trusted Metadata-Coordinated Tiered Off-Chain Storage for Recovery-Safe and Low-Latency IoT Data Management. Electronics* 在审.
6. *ZK-VOT: Establishing On-Chain/Off-Chain Mutual Trust via Zero-Knowledge Verifiable Oracle Transmission.* 投稿至WASA 2026.

* 表示共同一作；† 表示通讯作者。

专利

1. 韩蒙, **俞哲**, 胡佳妍, 邢文鹏, 林昶廷, 李荣昌, 陈友荣, 洪榛. 一种基于双路径内部状态强迫的检索增强生成幻觉检测方法. 中国发明专利, 申请号: 2026104125719, 申请日: 2026-03-31. (实质审查中)

企业研发经历

BoostEngine 2025年7月– 2025年10月
研发实习生（全栈开发/ AI Agents） 杭州，中国（与纽约团队远程协作）

- 面向中国跨境品牌与美国本土品牌共同使用的TikTok Shop 增长业务，负责多品牌Manifest V3 Chrome Extension（BoostEngine / ProBoost / Kaloboost）研发，基于React、TypeScript、Vite 与Chrome APIs 实现OAuth/验证码登录、in-page request relay、content script 数据采集与dashboard 模块，覆盖20 个区域站点与9 种语言环境。
- 围绕团队累计合作8000+ 达人、累计操盘数十万美元投放的业务场景，负责Spring Boot + MyBatis-Plus + MySQL/Redis 数据分析后台建设，开发达人、商品、店铺、视频等核心KPI 接口、TikTok Creator 指标聚合、报表与AI 邀约相关模块，支撑杭州研发团队与纽约团队跨时区协同的跨境增长决策。
- 独立设计并实现FastAPI + SQLAlchemy + Redis + React + Docker 的飞书多维表格/MySQL 双向同步系统，构建5 分钟哈希防环、队列合并、冲突处理、24 小时成功率监控，以及队列积压1000 条和失败率1% 的告警阈值，提升跨团队数据同步的稳定性与可运维性。

荣誉奖项

1. **“建行杯”浙江省国际大学生创新大赛（2024）银奖**，项目《脊柱侧弯检测AI 系统》项目骨干，融合计算机视觉与机器学习技术，实现脊柱侧弯风险评估与辅助诊断。

技术能力

- **研究栈**： Python, PyTorch, Hugging Face Transformers, scikit-learn, NumPy, pandas, FAISS, vLLM, Weights & Biases (W&B), MATLAB.
- **工程栈**： TypeScript/JavaScript, Java, React, FastAPI, Spring Boot, SQLAlchemy, MyBatis-Plus, MySQL, Redis, Docker, Chrome Extension（Manifest V3）.
- **研究主题**： Trustworthy LLMs, RAG faithfulness, hallucination detection, risk-guided decoding, medical LLM safety, verifiable attribution.

推荐人

韩蒙，研究实习导师，浙江大学研究员，mhan@zju.edu.cn.
邢文鹏，研究实习导师，浙江大学博士后研究员，wpxing@zju.edu.cn.
张紫阳，西湖大学导师，zhangziyang@westlake.edu.cn.
曾昊，浙江传媒学院导师，hao.zeng@cuz.edu.cn.