俞哲

研究助理| 可信语言模型与智能体AI

人工智能专业本科生| 预计2027 年毕业

香港科技大学（广州）| LAI Lab · 浙江大学| IFRC Lab

zyu@zju-if.com · 个人主页 · Google Scholar · GitHub

研究简介

围绕可信语言模型与智能体开展研究，结合白盒内部分析与系统级方法，重点研究证据归因、表征与行动分离、恶意技能检测及多智能体执行一致性。

教育经历

浙江传媒学院 **2023年– 预计2027年**

人工智能专业，工学学士在读；导师：曾昊 杭州，中国

平均分：85.15/100

科研经历

香港科技大学（广州） **2026年5月– 至今**

LAI Lab 研究助理；导师：秦成伟教授 广州，中国

- 开发CAVERT，诊断并恢复多智能体系统中的执行不一致；形式化任务义务及判定所需证据，区分记忆修正与实际执行合规。
- 参与推理全生命周期幻觉综述，将可观测证据与因果研究设计连接到验证、修复和输出控制。

乔治梅森大学（远程） **2026年6月– 9月**

研究实习生；导师：陈思敏教授 美国弗吉尼亚州费尔法克斯

- 开发LatentTriad，在单次预填充中探测声明、操作与边界表征，无需执行技能即可识别恶意智能体技能；研究跨技能来源与词汇诱饵的鲁棒性。

浙江大学滨江研究院 **2025年11月– 至今**

IFRC Lab 研究实习生；导师：韩蒙教授、邢文鹏博士 杭州，中国

- 开展DISF、FIDES 白盒RAG 可靠性研究，并通过Composition Collapse 区分事实知识稳定性与组合推理可靠性；FIDES和Composition Collapse 被EMNLP 2026 录用。
- 开展证据归因、审计规划与评估器可靠性研究；通过Readable Before Actionable 与Decodable but Unresolved 研究表征与行动分离。
- 在省级与国家重点研发计划下，开展LatentAudit 与RETINA-SAFE / ECRT 的忠实度监测与医疗风险分级研究，两篇论文均被NeurIPS 2026 Workshop 录用；参与ZK-FPE 隐私保护模型归属验证研究。

马来亚大学 **2025年1月– 2月**

访问学生 吉隆坡，马来西亚

- 参与与新加坡国立大学医学院合作的医疗计算机视觉项目。

西湖大学 **2024年3月– 9月**

研究助理；导师：张紫阳博士 杭州，中国

- 参与并行双全光纤干涉仪的盐度与温度检测研究，成果发表于*Optics Communications*（2025）。

企业研发经历

BoostEngine **2025年7月– 10月**

研发实习生（全栈开发/ AI Agents） 杭州，中国；与纽约团队远程协作

- 使用React、TypeScript、Vite 与Chrome APIs 构建面向TikTok Shop 的多品牌Manifest V3 扩展，覆盖20 个区域站点与9 种语言环境。
- 开发支持8000+ 达人合作的数据分析服务，以及包含防环、队列合并、监控与告警的FastAPI / Redis / MySQL 同步系统。

学术服务

审稿人： EMNLP 2026、NeurIPS 2026、AAAI 2027、ICLR 2027。

荣誉奖项与技术能力

- **“建行杯”浙江省国际大学生创新大赛银奖**，2024；项目《脊柱侧弯检测AI 系统》。
- **研究：** Python, PyTorch, Hugging Face Transformers, scikit-learn, NumPy, pandas, FAISS, vLLM, W&B, MATLAB.
- **工程：** TypeScript / JavaScript, Java, React, FastAPI, Spring Boot, SQLAlchemy, MyBatis-Plus, MySQL, Redis, Docker, Chrome Extensions.

已录用与发表论文

1. **Zhe Yu***, Wenpeng Xing*, Wenjie Luo, Weize Xu, Lingtong Huang, Yourong Chen, Changting Lin, Meng Han. *DISF: Detecting Hallucinations in Retrieval-Augmented Generation via Dual-path Internal State Forcing Framework*. **ACL 2026** 已录用. [PDF]
2. **Zhe Yu***, Wenpeng Xing*, Tiancheng Zhao, Mohan Li, Changting Lin, Meng Han. *FIDES: Faithful Inference via Deep Evidence Signals for Retrieval-Memory Conflict in RAG*. **EMNLP 2026 Main Conference**. [PDF]
3. **Zhe Yu***, Wenpeng Xing*, Yunzhao Wei, Hongzhi Wang, Xuyang Teng, Meng Han. *Composition Collapse: Stable Factual Knowledge Does Not Imply Compositional Reasoning*. **Findings of EMNLP 2026**. [arXiv]
4. **Zhe Yu***, Wenpeng Xing*, Meng Han. *LatentAudit: Real-Time White-Box Faithfulness Monitoring for Retrieval-Augmented Generation with Verifiable Deployment*. **NeurIPS 2026 Workshop** 已录用. [PDF]
5. **Zhe Yu***, Wenpeng Xing*, Meng Han. *From Retinal Evidence to Safe Decisions: RETINA-SAFE and ECRT for Hallucination Risk Triage in Medical LLMs*. **NeurIPS 2026 Workshop** 已录用. [PDF]
6. Zhiguo Ma*, **Zhe Yu**, Wenpeng Xing, Yourong Chen, Meng Han. *ZK-FPE: Blockchain-Verifiable Model Fingerprinting with Zero-Knowledge Privacy for Ownership Attribution*. **ACM TURC 2026**. [PDF]
7. Weiping Yu*, Weihan Wang*, Mingyuan Yan, Keyang He, **Zhe Yu**, Wenpeng Xing, Liyuan Liu, Meng Han. *Scalable and Trusted Metadata-Coordinated Tiered Off-Chain Storage with Dynamic On-Chain Mapping for Recovery-Safe and Low-Latency IoT Data Management*. *Electronics*, 2026, 15(13), 2806. [Publisher]
8. F. Zhou, C. Chang, Q. Chang, H. Zhang, **Zhe Yu**, W. Liu, J. Li, J. Yang. *Orthogonal salinity and temperature detection via paralleled dual all-fiber interferometers*. *Optics Communications*, 583 (2025): 131688. [DOI]
9. **Zhe Yu**, H. Zeng, Y. Zhao, X. Zhang, Z. Wang, Y. Tao, M. Yuan, X. Sun. *Bibliometric analysis of physical education research in China from 2014 to 2024*. **ACM ICETM**, 2025, pp. 128–132. [DOI]

在审论文

1. **Zhe Yu**, Mohan Li, Lei Yu, Ka-Ho Chow, Chengwei Qin, Xingyu Wu, Wenpeng Xing, Shuguang Xiong, Meng Han. *Hallucination Across the Reasoning Lifecycle: Interface Visibility, Causal Evidence, and Release Control in Large Reasoning Models*. **ACM Computing Surveys (CSUR)** 审稿中. [arXiv]
2. **Zhe Yu**, Zixuan Wang, Peidong Wang, Hehai Lin, Ruochen Zhao, Chengwei Qin. *Beyond Corrected Memory: Execution Consistency in Multi-Agent Systems*. **ICLR 2027** 审稿中. [arXiv]
3. **Zhe Yu**, Yi Liu, Ying Zhang, Simin Chen. *LatentTriad: Pre-Action Representation Probing for Malicious Agent Skill Detection*. **ICLR 2027** 审稿中. [PDF]
4. **Zhe Yu**, Wenpeng Xing, Zhenhua Xu, Xingxing Yang, Meng Han. *Readable Before Actionable: Causal Tracing of Indirect Prompt Injection*. **ICLR 2027** 审稿中. [arXiv]
5. **Zhe Yu**, Wenpeng Xing, Zhenhua Xu, Ruiqi Zhang, Meng Han. *Decodable but Unresolved: Chain-of-Thought Conflicts in Reasoning Models*. **ICLR 2027** 审稿中. [PDF]
6. **Zhe Yu**, Yunzhao Wei, Wenpeng Xing, Wenjie Luo, Zaobo He, Quan Chen, Meng Han. *PLAIT: From Hallucination Scores to Parent-Preserving Audit Plans*. **ICLR 2027** 审稿中. [PDF]
7. **Zhe Yu***, Wenpeng Xing*, Bo Yang, Chen Ye, Gaolei Li, Yunzhao Wei, Meng Han. *The Attribution Blind Spot: Detecting When Language Models Rely on Memory Rather Than Retrieved Context*. **ICLR 2027** 审稿中. [arXiv]
8. **Zhe Yu***, Wenpeng Xing*, Chen Ye, Xuyang Teng, Bo Yang, Changting Lin, Meng Han. *Calibration Does Not Certify a Contrast: Identification and Correction for LLM Evaluators*. **AAAI 2027** 审稿中. [PDF]
9. **Zhe Yu***, Wenpeng Xing*, Gaolei Li, Shuguang Xiong, Hongzhi Wang, Xuyang Teng, Meng Han. *Cordon-MAS: Defending RAG against Knowledge Poisoning via Information-Flow Control*. **ARR** 审稿中. [arXiv]
10. Zhenhua Xu, Qichen Liu, Zhebo Wang, **Zhe Yu**, Xixiang Zhao, Wenpeng Xing, Dezhang Kong, Mohan Li, Meng Han. *Fingerprint Vector: Enabling Scalable and Efficient Model Fingerprint Transfer via Vector Addition*. **ARR (October 2026)** 审稿中. [PDF]

* 表示共同一作；稿件状态更新于2026 年10 月12 日。

专利

1. **Zhe Yu**, Wenpeng Xing, Meng Han. *A hallucination detection method based on dual-path internal state forcing logic for retrieval-augmented generation in large language models*. 中国发明专利申请号202610260408X；实质审查中.
2. Meng Han, **Zhe Yu**, Jiayan Hu, Rongchang Li, Wenpeng Xing, Jingyi Yu, Zhen Hong, et al.. *A post-processing method, system, device, and medium for hallucination detection in large language models based on adaptive order statistics aggregation*. 中国发明专利申请号2026107898102；2026年6月3日申请，已受理.
3. **Zhe Yu**, Jiayan Hu, Jingyi Yu, Weihang Yu, Wenpeng Xing, Jing Xiong, Yourong Chen, Zhen Hong, et al.. *A hallucination detection method, system, and device for large language models based on multi-dimensional heterogeneous feature fusion*. 中国发明专利申请号2026107899270；2026年6月3日申请，已受理.